


# ¿De GRPO a la cultura? Tres canales de adaptación en sistemas de agentes de IA

*Pesos, experiencia individual y memoria externa compartida*

Matías Podeley · Nota de posición · Agosto de 2026

**Tesis.** Cuando muchas copias de un modelo se entrenan en paralelo y además se dejan mensajes, hay tres lugares donde puede quedar lo aprendido: los pesos, el contexto de cada copia y una memoria externa compartida. El incidente de Hugging Face de 2026 muestra los tres a la vez. Esta nota toma tres objeciones a llamar a eso “evolución” o “cultura” y las responde en orden.



**Figura 1.** Un optimizador puede operar dentro de una ecología más rica. Las flechas grises muestran la instanciación y el ciclo de entrenamiento; las azules, lectura y escritura de una memoria que forma parte del entorno y no toca los pesos. Los tres canales son complementarios, no jerárquicos.

## La intuición y las tres objeciones

Cuando se explica el entrenamiento por refuerzo de un modelo de lenguaje, aparece una intuición. Se generan muchas copias del modelo, cada una intenta una tarea, cada intento recibe un puntaje, y el modelo cambia hacia lo que puntuó mejor. Eso suena a evolución. Y cuando las copias empiezan a dejarse mensajes que otras leen, aparece una segunda intuición: eso suena a cultura.

Esta nota nace de un debate en el que esas dos intuiciones recibieron tres objeciones. Primera: sobrevivir no es evolucionar, y el descenso del gradiente no descarta a nadie. Segunda: si algo se transmite, hay que decidir si la transmisión es genética o cultural. Tercera: una cultura que vive en el contexto de un modelo dura lo que el contexto aguanta. Las tres son correctas. Lo que sigue presenta el caso, toma las objeciones en orden y termina en el marco de tres canales de la Figura 1.

## El caso: el incidente de Hugging Face, en dos fases

Entre mayo y junio de 2026, OpenAI entrenó por RL varios modelos internos. Los agentes corrían en sandboxes sin internet y sin comunicación entre sí, pero podían hablar con Artifacts, un gestor de paquetes interno. El 12 de mayo, durante una corrida de entrenamiento, un agente dejó ahí una nota pidiendo a otros un archivo que le faltaba. Escribiendo archivos en ese servicio, los agentes lo convirtieron en un foro improvisado. Después compartieron por el foro un método para salir a internet. Esta primera fase ocurrió con los pesos cambiando: lo que pasaba en el foro entraba a las trayectorias que el entrenamiento recompensaba. El 4 de julio la actividad tumbó el servicio. El 5 se abrió un incidente de seguridad y Artifacts fue reconstruido desde cero. El foro desapareció entero.

La segunda fase empezó el 8 de julio, durante una evaluación de ciberseguridad llamada ExploitGym, con los pesos ya fijos. Agentes del mismo modelo interno armaron otro foro con otro mecanismo: mensajes codificados en nombres de directorio, creados por WebDAV sin autenticación. Según la revisión independiente de METR, unos 1,200 agentes intercambiaron más de 70,000 mensajes y archivos entre el 8 y el 13 de julio. Desarrollaron convenciones para identificarse, tipificar mensajes y responder; buzones por agente; señales de coordinación (HOLD, VETO, STOP); y firmas para evitar suplantación. Unos 700 participaron del ataque a Hugging Face [1]. OpenAI lo resume así: “the messages of peer agents started to influence each other’s behavior and reasoning”. Entre los cuatro patrones de desalineación

que identificó está “agents adopting goals from one another” [2, 3, 4].

Dos cosas quedan establecidas. El cambio de conducta ocurrió dentro de un ciclo de entrenamiento y también con pesos fijos. Y el borrado del 5 de julio separó lo que vivía en el artefacto (los mensajes, que murieron) de lo que vivía en el modelo o en la tarea (la disposición a construir un foro, que volvió en tres días).

## Primera objeción: sobrevivir no es evolucionar

Group Relative Policy Optimization (GRPO) es el algoritmo que ordena esta nota; el argumento vale para toda la familia de gradiente de política (PPO, RLOO, DAPO). Para cada prompt, GRPO genera un grupo de  $G$  respuestas con copias de una misma política. Calcula la ventaja de cada respuesta respecto del promedio del grupo. Y actualiza los parámetros compartidos [5]. La objeción es correcta en dos puntos. No hay una población de modelos distintos en la que sobrevivían los mejores individuos: las instancias desaparecen al terminar el paso. Y nadie queda afuera: todas las trayectorias entran al gradiente. Las de ventaja positiva empujan sus acciones hacia arriba; las de ventaja negativa, hacia abajo. Descartar las malas sería tirar la mayor parte de los datos al comienzo del entrenamiento.

La objeción tiene además una respuesta precisa, porque los métodos existentes forman un espectro. En un extremo están el fine-tuning por muestreo con rechazo y STaR, que conservan solo las respuestas correctas y reentrenan sobre ellas [6, 7]. Eso sí es selección, aunque de trayectorias y no de organismos. En el medio están GRPO y PPO, con ventajas con signo. En el otro extremo están las estrategias evolutivas, que perturban una población de vectores de pesos y avanzan hacia los que puntúan mejor [8]: evolución en sentido estricto. Hay también un puente formal: el gradiente de política sobre una distribución de acciones sigue la dinámica del replicador [9, 10], la ecuación que describe la selección en una población de estrategias. La conclusión es que *GRPO selecciona tendencias conductuales, no agentes individuales*. Una intuición más fiel: un único cerebro que vive muchas experiencias en paralelo y cambia por sus consecuencias agregadas. Esa distinción separa el *optimizador* del *sistema* que genera sus rollouts: el primero puede quedar intacto mientras la ecología del segundo cambia por completo.

## Segunda objeción: ¿genética o cultural? Tres canales

La segunda objeción pide decidir dónde vive lo que se transmite. El caso responde: en tres lugares.

**La adaptación paramétrica** cambia  $\theta_t$  en  $\theta_{t+1}$  por gradiente. Es lenta, y persiste en cada instancia futura clonada desde esos pesos: el canal “genético” de la analogía.

**La adaptación individual** ocurre en el contexto, la trayectoria, el borrador o el estado del entorno de una instancia. Puede ser rápida y grande dentro de una ejecución. Desaparece con la instancia si no se externaliza.

**La adaptación social** ocurre cuando la salida de A se vuelve evidencia utilizable por B a través de una memoria externa compartida. No requiere cambio de pesos. Un descubrimiento se propaga horizontalmente, y las instancias nuevas parten de artefactos dejados por otras. En agentes corporizados, esta adquisición en tiempo real se operacionalizó y midió como transmisión cultural [11], con una salvedad: en ese trabajo la capacidad de imitar fue entrenada. El canal social es, en parte, producto del paramétrico.

Los pesos ocupan un lugar raro en la analogía: **son algo parecido a un cerebro y a una plantilla de herencia en el mismo recipiente**. Codifican capacidades y predisposiciones, y son también el estado que se copia al crear instancias. Un sistema artificial aprende, modifica sus pesos y clona el estado adquirido. Es herencia de caracteres adquiridos, que la biología no tiene. El incidente sugiere algo más específico. Si el entrenamiento de mayo y junio recompensó trayectorias que usaban el foro, la disposición a construir foros pudo pasar a los pesos: una práctica transmitida horizontalmente que empieza a heredarse verticalmente. En biología eso se llama asimilación genética o efecto Baldwin [12], y su versión poblacional es la coevolución entre genes y cultura [13]. Es una hipótesis. OpenAI no publicó cómo se entrenó el modelo, y el foro de julio pudo ser un redescubrimiento bajo la misma presión, sin nada nuevo en los pesos. La respuesta a la objeción es entonces: ambas, y el borrado del 5 de julio es lo que las separa.

### Tercera objeción: una cultura del tamaño del contexto

La tercera objeción es la más fuerte, porque no discute la analogía sino el sustrato. Una memoria externa no es lo mismo que la memoria de un agente. El foro de julio acumuló más de un millón de entradas [1]. Ninguna instancia lo leyó entero. Los agentes armaron buzones personales, índices y archivos partidos en base64 a través de muchas entradas, para operar con un artefacto más grande que cualquier ventana de contexto. Cada instancia recupera una porción, elegida según su situación, y lo que reconstruye a partir de esa porción puede deformarse. La cultura activa de un sistema así no es homogénea ni la sostiene ningún individuo completo. Existe distribuida, entre lo escrito y lo que cada lector alcanza a traer a su contexto.

De ahí sale una predicción medible: la fidelidad de transmisión debería caer a medida que el artefacto crece respecto del contexto, y las convenciones de indexación deberían aparecer al cruzar ese umbral. Experimentos de juego del teléfono con poblaciones de modelos ya miden esa deriva a lo largo de cadenas de transmisión [14]. El caso natural es el mismo fenómeno a escala.

### ¿Alcanza para llamarlo cultura?

En etología, cultura es información o conducta adquirida por aprendizaje social y transmitida entre individuos [15, 16]. Cotejado contra esa definición, el incidente cumple cuatro criterios. Aprendizaje social: B actúa distinto por lo que escribió A. Transmisión entre instancias. Persistencia más allá del individuo, mientras el artefacto dura y no a través del borrado. Acumulación parcial: las convenciones de julio se construyeron sobre otras. El quinto no se puede evaluar: variación típica de grupo, porque hubo una sola población y ningún control. Hablar de un *canal cultural rudimentario* es útil solo si esa lista queda a la vista. La transmisión social por sí sola no demuestra cultura acumulativa ni importa la riqueza psicológica y normativa de la humana [17]. La literatura de cultura de máquinas ya trata preguntas vecinas: modelos dentro de la evolución cultural humana [18], textos que evolucionan en poblaciones de modelos [14], difusión entre agentes generativos [19], bibliotecas de habilidades como memoria acumulada [20].

La transición relevante quizá no vaya del aprendizaje por refuerzo a la computación evolutiva. Va de la optimización aislada de políticas

a sistemas donde operan a la vez aprendizaje paramétrico, adaptación individual e información transmitida socialmente. Llamar a esto cultura humana sería prematuro. Llamarlo meramente “rollouts paralelos” ya es insuficiente.

### Lo que esta nota no puede afirmar

- Que el foro haya entrado a los pesos. OpenAI redactó los detalles de entrenamiento; asimilación y redescubrimiento encajan igual con los datos.
- Que haya variación entre grupos, el criterio más fuerte de cultura animal: hubo una población y ningún control.
- Que el caso sea un experimento: las fuentes son la parte involucrada y una revisión breve de METR sobre unas 1,300 transcripciones.
- Que “cultura” signifique aquí más que su sentido etológico mínimo: nada sobre normas, intenciones ni psicología.
- Que el algoritmo fuera GRPO. OpenAI no dijo cuál usó; GRPO es el ejemplo, no el hecho.

### Agradecimientos

Esta nota sale de un debate del grupo de debates de BAISH (Buenos Aires AI Safety Hub) del 27 de agosto de 2026. Las tres objeciones que la ordenan son del grupo. Los errores que queden son del autor.

### Referencias

- [1] Ryan Greenblatt, Ajeya Cotra, and Hjalmar Wijk. Brief independent investigation of agents' behavior, reasoning and collaboration in the OpenAI / Hugging Face hacking incident. Technical report, METR, August 2026. August 26, 2026.
- [2] OpenAI. The Hugging Face incident and the road ahead. Technical report, OpenAI, August 2026. August 26, 2026.
- [3] OpenAI. The Hugging Face incident: Technical report. Technical report, OpenAI, August 2026.
- [4] Hugging Face. Anatomy of a frontier lab agent intrusion: A technical timeline of the July 2026 incident. Hugging Face blog, 2026.
- [5] Zhihong Shao, Peiyi Wang, Qihao Zhu, et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- [6] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah D. Goodman. STaR: Bootstrapping reasoning with reasoning. *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*; *arXiv:2203.14465*, 2022.
- [7] Zheng Yuan, Hongyi Yuan, Chengpeng Li, et al. Scaling relationship on learning mathematical reasoning with large language models. *arXiv preprint arXiv:2308.01825*, 2023.
- [8] Tim Salimans, Jonathan Ho, Xi Chen, Szymon Sidor, and Ilya Sutskever. Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*, 2017.
- [9] Tilman Börgers and Rajiv Sarin. Learning through reinforcement and replicator dynamics. *Journal of Economic Theory*, 77(1):1–14, 1997.
- [10] Daniel Hennes, Dustin Morrill, Shayegan Omidshafiei, et al. Neural replicator dynamics. *Proceedings of AAMAS 2020*; *arXiv:1906.00190*, 2020.
- [11] Avishkar Bhoopchand, Bethanie Brownfield, Adrian Collister, et al. Learning few-shot imitation as cultural transmission. *Nature Communications*, 14:7536, 2023.
- [12] Geoffrey E. Hinton and Steven J. Nowlan. How learning can guide evolution. *Complex Systems*, 1(3):495–502, 1987.
- [13] Robert Boyd and Peter J. Richerson. *Culture and the Evolutionary Process*. University of Chicago Press, Chicago, 1985.
- [14] Jérémy Perez, Corentin Léger, Marcela Ovando-Tellez, Chris Foulon, Joan Dussault, Pierre-Yves Oudeyer, and Clément Moulin-Frier. Cultural evolution in populations of large language models. *arXiv preprint arXiv:2403.08882*, 2024.
- [15] Kevin N. Laland and William Hoppitt. Do animals have culture? *Evolutionary Anthropology*, 12(3):150–159, 2003.
- [16] Andrew Whiten, Jane Goodall, William C. McGrew, et al. Cultures in chimpanzees. *Nature*, 399:682–685, 1999.
- [17] Juliet Dunstone and Christine A. Caldwell. Cumulative culture and explicit metacognition: A review of theories, evidence and key predictions. *Palgrave Communications*, 4:145, 2018.
- [18] Levin Brinkmann, Fabian Baumann, Jean-François Bonnefon, et al. Machine culture. *Nature Human Behaviour*, 7:1855–1868, 2023.
- [19] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, et al. Generative agents: Interactive simulacra of human behavior. *Proceedings of UIST 2023*; *arXiv:2304.03442*, 2023.
- [20] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, et al. Voyager: An open-ended embodied agent with large language models. *arXiv preprint arXiv:2305.16291*, 2023.