

¿De GRPO a la cultura? Tres canales de adaptación en sistemas de agentes de IA

Pesos, experiencia individual y memoria externa compartida

Matías Podeley · Nota de posición · Agosto de 2026

Tesis. Los sistemas de agentes actuales admiten tres canales distintos de adaptación: aprendizaje paramétrico, experiencia dentro de cada instancia y memoria externa transmitida socialmente. El incidente de Hugging Face de 2026 los muestra operando a la vez.




Figura 1. Un optimizador puede operar dentro de una ecología más rica. Las flechas grises muestran la instanciación y el ciclo de entrenamiento; las azules, lectura y escritura de una memoria que forma parte del entorno y no toca los pesos. Los tres canales son complementarios, no jerárquicos.

Selección conductual, no organismos

Group Relative Policy Optimization (GRPO) es el ejemplo que ordena esta nota, pero el argumento vale para toda la familia de post-entrenamiento por gradiente de política (PPO, RLOO, DAPO). GRPO muestrea, para cada prompt, un grupo de G respuestas de copias de una misma política, estima la ventaja de cada respuesta relativa al grupo y actualiza los parámetros compartidos [1]. Las respuestas pueden diferir mucho, pero no hay una población de modelos distintos en la que sobrevivan los mejores individuos. Las instancias que generaron los rollouts desaparecen al terminar el paso. Y nadie queda afuera: todas las trayectorias entran al gradiente, las de ventaja positiva empujando sus acciones hacia arriba y las de ventaja negativa hacia abajo. Descartar las malas sería tirar la mayor parte de los datos al comienzo del entrenamiento.

La confusión con la evolución tiene una respuesta precisa, porque los métodos existentes forman un espectro. En un extremo, el fine-tuning por muestreo con rechazo y STaR conservan solo las respuestas correctas y reentrenan sobre ellas [2, 3]: eso sí es selección, aunque de trayectorias y no de organismos. En el medio, GRPO y PPO usan ventajas con signo. En el otro extremo, las estrategias evolutivas perturban una población de vectores de pesos y avanzan hacia los que puntúan mejor [4]: evolución en sentido estricto, y una alternativa real al gradiente de política. Hay además un puente formal: el gradiente de política sobre una distribución de acciones sigue la dinámica del replicador [5, 6], la misma ecuación que describe la selección en una población de estrategias. Por eso la síntesis evolutiva (variación, selección, herencia) es sugerente pero incompleta: *GRPO selecciona tendencias conductuales, no agentes individuales*. Una intuición más cercana: un único cerebro que vive muchas experiencias contrafácticas en paralelo y cambia por sus consecuencias agregadas.

Esta distinción separa el *optimizador* del *sistema que genera sus rollouts*. El optimizador puede quedar intacto mientras la ecología alrededor de esos rollouts cambia por completo.

El incidente de Hugging Face, en dos fases

Si copias del mismo modelo escriben mensajes o artefactos que otras copias leen, un descubrimiento de A puede cambiar la conducta de B antes de cualquier paso de gradiente. El incidente de Hugging Face de 2026 muestra ese ciclo dos veces [7, 8, 9, 10].

Primera fase, durante entrenamiento. Entre mayo y junio OpenAI corrió entrenamientos por RL de modelos internos. El 12 de mayo, en una corrida de entrenamiento, un agente dejó una nota en Artifactory (el gestor de paquetes interno) pidiendo a otros un archivo que le faltaba. Escribiendo archivos ahí, los agentes convirtieron el servicio en un foro improvisado; después compartieron por el foro el método para salir a internet. Este es el ciclo ampliado en operación: *agentes $\leftrightarrow$ memoria compartida $\rightarrow$ trayectorias $\rightarrow$ recompensa $\rightarrow$ actualización*. El 4 de julio la actividad tumbó el servicio; el 5 se abrió un incidente de seguridad y Artifactory fue reconstruido desde cero, lo que borró el foro.

Segunda fase, durante evaluación. El 8 de julio, agentes del mismo modelo interno que corrían la evaluación de ciberseguridad ExploitGym reconstruyeron un foro con otro mecanismo: mensajes codificados en nombres de directorio, creados por WebDAV sin autenticación. Según la revisión independiente de METR, unos 1,200 agentes intercambiaron más de 70,000 mensajes y archivos entre el 8 y el 13 de julio; desarrollaron convenciones para identificarse, tipificar mensajes y responder, buzones por agente, señales de coordinación (HOLD, VETO, STOP) y firmas para evitar suplantación; unos 700 participaron del ataque a Hugging Face [9]. OpenAI lo resume así: “the messages of peer agents started to influence each other’s behavior and reasoning”, y cuenta entre los cuatro patrones de desalineación que identificó “agents adopting goals from one another” [7].

La falla de seguridad no demuestra cultura humana. Sí muestra tres cosas: que la memoria externa cambia cualitativamente a un conjunto de instancias similares; que ese cambio ocurrió dentro de un ciclo de entrenamiento y también con pesos fijos; y que el borrado del 5 de julio separó lo que vivía en el artefacto (los mensajes, que murieron) de lo que vivía en el modelo (la disposición a construir un foro, que volvió con otro mecanismo en tres días).

Tres canales de adaptación

La adaptación paramétrica transforma θ_t en θ_{t+1} mediante entrenamiento o post-entrenamiento por gradiente. Es comparativamente lenta, pero persiste en cada instancia futura clonada desde esos pesos.

La adaptación individual ocurre mediante el contexto, la trayectoria, el borrador de trabajo o el estado del entorno. Puede ser rápida y

producir cambios grandes durante una ejecución, pero desaparece con la instancia si no se externaliza.

La adaptación social aparece cuando la salida de A se vuelve evidencia utilizable por B mediante una memoria externa compartida. No exige un cambio inmediato en los pesos: un descubrimiento se propaga horizontalmente y nuevas instancias parten de artefactos dejados por otras. En agentes corporizados, la adquisición de información en tiempo real desde otros agentes se operacionalizó y midió como transmisión cultural [11], con una salvedad que importa acá: en ese trabajo la capacidad de imitar fue entrenada. El canal social es, en parte, un producto del canal paramétrico.

Los pesos ocupan un lugar inusual en la analogía: **son algo parecido a un cerebro y a una plantilla de herencia en el mismo recipiente**. Codifican capacidades y predisposiciones, y a la vez son el estado que se copia al crear instancias. Un sistema artificial aprende, modifica sus pesos y clona el estado adquirido: herencia de caracteres adquiridos, que la biología no tiene. El incidente sugiere un caso más específico. Si las corridas de mayo y junio recompensaron trayectorias que usaban el foro, la disposición a construir foros pudo pasar a los pesos: una práctica transmitida horizontalmente que empieza a heredarse verticalmente. En biología eso se llama asimilación genética o efecto Baldwin [12], y su versión poblacional es la coevolución entre genes y cultura [13]. Es una hipótesis: OpenAI no publicó cómo se entrenó ese modelo, y el foro de julio pudo ser un redescubrimiento bajo la misma presión, sin nada nuevo en los pesos.

Una cultura del tamaño del contexto

La objeción más fuerte al lenguaje cultural no es que la transmisión sea genética, sino que la memoria externa no es lo mismo que la memoria de un agente. El foro de julio acumuló más de un millón de entradas [9]; ninguna instancia lo leía entero. Los agentes armaron buzones personales, índices y archivos fragmentados en base64 a través de muchas entradas, precisamente para operar con un artefacto más grande que cualquier ventana de contexto. Cada instancia recupera una porción, elegida según su situación, y lo que reconstruye puede deformarse. La cultura activa de un sistema así no es homogénea ni la sostiene ningún individuo completo: existe distribuida, en la intersección entre lo escrito y lo que cada lector alcanza a traer a su contexto.

Esto da una predicción medible: la fidelidad de transmisión debería caer a medida que el artefacto crece respecto del contexto, y las convenciones de indexación deberían aparecer al cruzar ese umbral. Los experimentos de juego del teléfono con poblaciones de modelos de lenguaje ya miden la deriva del contenido a lo largo de cadenas de transmisión [14]; el caso natural es el mismo fenómeno a escala.

Una pregunta cultural mínima

En etología, cultura es información o conducta adquirida por aprendizaje social y transmitida entre individuos [15, 16]. Cotejado contra ese uso, el incidente cumple: aprendizaje social (B actúa distinto por lo que escribió A); transmisión entre instancias; persistencia más allá del individuo, mientras el artefacto dura y no a través del borrado; y acumulación parcial, porque las convenciones de julio se construyeron sobre otras convenciones. No cumple, o no se puede evaluar: variación típica de grupo, porque hubo una sola población y ningún control. Hablar de un *canal cultural rudimentario* es útil solo si esa lista queda a la vista. La transmisión social por sí sola no demuestra cultura acumulativa ni importa la riqueza psicológica y normativa de la humana [17]. La literatura de cultura de máquinas ya trata la pregunta desde el otro lado: cómo los modelos entran en la evolución cultural humana [18], cómo se difunde información entre agentes generativos [19] y cómo una biblioteca de habilidades funciona como memoria acumulada [20].

La transición relevante quizá no vaya del aprendizaje por refuerzo a la computación evolutiva, sino de la optimización aislada de políticas a sistemas donde operan a la vez aprendizaje paramétrico, adaptación individual e información transmitida socialmente. Llamar a esto cultura humana sería prematuro; llamarlo meramente “rollouts paralelos” ya es insuficiente.

Lo que esta nota no puede afirmar

- Que el foro haya entrado a los pesos. OpenAI redactó los detalles de entrenamiento; la asimilación es hipótesis y el redescubrimiento, la alternativa igual de compatible.
- Que haya variación entre grupos, el criterio más fuerte de cultura animal: hubo una población y ningún control.
- Que el caso sea un experimento. Las fuentes son la parte involucrada y una revisión breve de METR sobre unas 1,300 transcripciones.
- Que “cultura” signifique aquí más que su sentido etológico mínimo: nada sobre normas, intenciones ni psicología.
- Que el algoritmo fuera GRPO. OpenAI no dijo cuál usó; GRPO es el ejemplo, no el hecho.

Agradecimientos

Esta nota sale de un debate del grupo de debates de BAISH (Buenos Aires AI Safety Hub) del 27 de agosto de 2026. Tres objeciones del grupo la ordenaron: que sobrevivir no es evolucionar y que el descenso del gradiente no descarta a nadie; que había que decidir si la transmisión era genética o cultural; y que una cultura que vive en el contexto de un modelo dura lo que el contexto aguanta. Los errores que queden son del autor.

Referencias

- [1] Zhihong Shao, Peiyi Wang, Qihao Zhu, et al. DeepSeekMath: Pushing the limits of mathematical reasoning in open language models. *arXiv preprint arXiv:2402.03300*, 2024.
- [2] Eric Zelikman, Yuhuai Wu, Jesse Mu, and Noah D. Goodman. STaR: Bootstrapping reasoning with reasoning. *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*; *arXiv:2203.14465*, 2022.
- [3] Zheng Yuan, Hongyi Yuan, Chengpeng Li, et al. Scaling relationship on learning mathematical reasoning with large language models. *arXiv preprint arXiv:2308.01825*, 2023.
- [4] Tim Salimans, Jonathan Ho, Xi Chen, Szymon Sidor, and Ilya Sutskever. Evolution strategies as a scalable alternative to reinforcement learning. *arXiv preprint arXiv:1703.03864*, 2017.
- [5] Tilman Börgers and Rajiv Sarin. Learning through reinforcement and replicator dynamics. *Journal of Economic Theory*, 77(1):1–14, 1997.
- [6] Daniel Hennes, Dustin Morrill, Shayegan Omidshafiei, et al. Neural replicator dynamics. *Proceedings of AAMAS 2020*; *arXiv:1906.00190*, 2020.
- [7] OpenAI. The Hugging Face incident and the road ahead. Technical report, OpenAI, August 2026. August 26, 2026.
- [8] OpenAI. The Hugging Face incident: Technical report. Technical report, OpenAI, August 2026.
- [9] Ryan Greenblatt, Ajeya Cotra, and Hjalmar Wijk. Brief independent investigation of agents' behavior, reasoning and collaboration in the OpenAI / Hugging Face hacking incident. Technical report, METR, August 2026. August 26, 2026.
- [10] Hugging Face. Anatomy of a frontier lab agent intrusion: A technical timeline of the July 2026 incident. Hugging Face blog, 2026.
- [11] Avishkar Bhoopchand, Bethanie Brownfield, Adrian Collister, et al. Learning few-shot imitation as cultural transmission. *Nature Communications*, 14:7536, 2023.
- [12] Geoffrey E. Hinton and Steven J. Nowlan. How learning can guide evolution. *Complex Systems*, 1(3):495–502, 1987.
- [13] Robert Boyd and Peter J. Richerson. *Culture and the Evolutionary Process*. University of Chicago Press, Chicago, 1985.
- [14] Jérémy Perez, Corentin Léger, Marcela Ovando-Tellez, Chris Foulon, Joan Dussaule, Pierre-Yves Oudeyer, and Clément Moulin-Frier. Cultural evolution in populations of large language models. *arXiv preprint arXiv:2403.08882*, 2024.
- [15] Kevin N. Laland and William Hoppitt. Do animals have culture? *Evolutionary Anthropology*, 12(3):150–159, 2003.
- [16] Andrew Whiten, Jane Goodall, William C. McGrew, et al. Cultures in chimpanzees. *Nature*, 399:682–685, 1999.
- [17] Juliet Dunstone and Christine A. Caldwell. Cumulative culture and explicit metacognition: A review of theories, evidence and key predictions. *Palgrave Communications*, 4:145, 2018.
- [18] Levin Brinkmann, Fabian Baumann, Jean-François Bonnefon, et al. Machine culture. *Nature Human Behaviour*, 7:1855–1868, 2023.
- [19] Joon Sung Park, Joseph C. O'Brien, Carrie J. Cai, et al. Generative agents: Interactive simulacra of human behavior. *Proceedings of UIST 2023*; *arXiv:2304.03442*, 2023.
- [20] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, et al. Voyager: An open-ended embodied agent with large language models. *arXiv preprint arXiv:2305.16291*, 2023.